

Otimização da Seleção de Features através de Programação Genética em Modelos de Machine Learning

Intelligent Systems



INOVA-
RIA:
Sacchetti



INOVA-RIA - Associação de
Empresas para uma Rede
Inovação em Aveiro



Thiago
Andrade

Published & Assigned

Tutor at hosting institution

João Almeida - joaofilipeferreiraalmeida@gmail.com -
Data Scientist

Context

A crescente disponibilidade de dados tem levado ao desenvolvimento de modelos de Machine Learning com um número elevado de variáveis, nem sempre devidamente exploradas do ponto de vista das suas interações. Em muitos cenários, a seleção de features é feita com base em métricas de importância individuais ou através de processos simplificados, que podem falhar na identificação de combinações de variáveis cujo valor emerge apenas quando consideradas em

conjunto. Esta limitação torna-se particularmente relevante em modelos clássicos de ML, onde a escolha do conjunto de features influencia diretamente a capacidade do modelo em capturar padrões relevantes. Neste contexto, abordagens inspiradas em computação evolutiva, como a programação genética, surgem como uma alternativa promissora para explorar de forma estruturada o espaço de possíveis conjuntos de features, permitindo identificar relações de complementaridade que dificilmente seriam captadas por métodos tradicionais.

Objectives

Objetivo geral Investigar a utilização de programação genética como abordagem para a seleção de conjuntos de features no treino de modelos clássicos de Machine Learning, com foco na identificação de combinações de variáveis que se complementem e contribuam para um melhor desempenho do modelo. Objetivos específicos • Analisar e sintetizar o estado da arte em métodos de seleção de features, incluindo abordagens baseadas em importância individual, métodos aleatórios e técnicas evolutivas; • Estudar os princípios da programação genética e a sua aplicação em problemas de otimização combinatória no contexto de Machine Learning; • Desenvolver uma metodologia baseada em programação genética para a seleção automática de feature sets, considerando o desempenho do modelo como critério de avaliação; • Comparar a abordagem proposta com métodos tradicionais de seleção de features, avaliando métricas como desempenho

preditivo, robustez e custo computacional; •Analisar os conjuntos de features obtidos, com o objetivo de identificar padrões de complementaridade entre variáveis e compreender o seu impacto no comportamento do modelo.

Innovation

- Seleção de features ao nível do conjunto, capturando interações e complementaridades entre variáveis.
- Uso de programação genética para explorar de forma eficiente o espaço de combinações de features.
- Avaliação direta pelo desempenho do modelo, alinhando a seleção com o objetivo final de treino.
- Equilíbrio entre exploração e interpretabilidade, combinando abordagens evolutivas e métricas tradicionais.
- Metodologia genérica e reutilizável, aplicável a diferentes modelos clássicos e domínios de dados.

Workplan

- Revisão do estado da arte em seleção de features e programação genética.
- Avaliação de métodos e ferramentas existentes.
- Desenvolvimento de abordagem baseada em programação genética para seleção de feature sets.
- Testes e validação com modelos clássicos de ML.
- Documentação e criação de diretrizes de uso.
- Recolha de feedback e ajustes iterativos.
- Redação do relatório final.

Bibliography

• Rodrigues, N. M., Batista, J. E., Cava, W. L., et al. (2024). Exploring SLUG: Feature Selection Using Genetic Algorithms and Genetic Programming. SN Computer Science. Disponível em: <https://link.springer.com/article/10.1007/s42979-023-02106-3>

• Improving Generalization of Genetic Programming for High-Dimensional Symbolic Regression with Shapley Value Based Feature Selection - trabalho recente que combina GP com métodos de importância de features como Shapley Values. Disponível em: <https://link.springer.com/article/10.1007/s41019-024-00270-x>

• Mweshi, G. (2019). Feature Selection using Genetic Programming. Zambia ICT Journal. <https://doi.org/10.33260/zictjournal.v3i2.62>

Profile

• Programação e dados: Python (Pandas, NumPy) e manipulação de datasets. • Machine Learning: Experiência com pipelines de ML e scikit-learn (valorizam-se PyTorch/TensorFlow). • Estatística: Noções de avaliação de variáveis, redundância e qualidade de dados. • Raciocínio analítico: Capacidade de definir critérios e interpretar resultados de seleção de features. • Autonomia e trabalho de equipa: Capacidade de conduzir investigação e experimentar de forma independente, com boa comunicação.

Venues

A definir entre Orientadores e aluno

Additional Notes

"Com possibilidade de integrar Bolsa de Investigação - Programa GENIUS/Inova-Ria - durante a realização do projeto de Dissertação - Integração numa equipa de I&D na Empresa Altice Labs (E.A.) . • Horário: De acordo com enquadramento da Universidade • Formato: (a combinar na entrevista) • Meios: atribuição de um PC portátil e acessos à rede Interna da Altice Labs • Kit de Acolhimento • Onboarding nas equipas da Altice Labs, com atribuição de um Orientadorfull-time • Possibilidade de participar em todas as iniciativas de partilha de conhecimento ou de entretenimento levadas a cabo pela Altice Labs • Possibilidade de entrada nos quadros da empresa Os alunos interessados deverão enviar para genius@inova-ria.pt . • Curriculum Vitae; • Disciplinas realizadas até ao momento com médias; simples documento eletrónico, que poderá obter no portal académico . • Top 3 áreas de interesse. • Requisito média 13,5-14 valores (média linear Lic-Msc)"

Enviar a tua candidatura: genius@inova-ria.pt

Nota:A aceitação de estudantes estará sempre condicionada às necessárias aprovações internas, e respetivas entrevistas, não implicando uma alocação automática.